19 | 深入理解迭代器和生成器

2019-06-21 暑雪

Python核心技术与实战

进入课程 >



讲述: 冯永吉

时长 10:34 大小 8.48M



你好,我是景霄。

在第一次接触 Python 的时候, 你可能写过类似 for i in [2, 3, 5, 7, 11, 13]: print(i) **这样的语句。for** in 语句理解起来很直观形象, 比起 C++ 和 java 早期的

for (int i = 0; i < n; i ++) printf("%d\n", a[i]) 这样的语句,不知道简洁清晰到哪里去了。

但是,你想过 Python 在处理 for in 语句的时候,具体发生了什么吗? 什么样的对象可以被 for in 来枚举呢?

这一节课,我们深入到 Python 的容器类型实现底层去走走,了解一种叫做迭代器和生成器的东西。

你肯定用过的容器、可迭代对象和迭代器

容器这个概念非常好理解。我们说过,在 Python 中一切皆对象,对象的抽象就是类,而对象的集合就是容器。

列表(list: [0, 1, 2]) ,元组(tuple: (0, 1, 2)) ,字典 (dict: {0:0, 1:1, 2:2}) ,集合(set: set([0, 1, 2]))都是容器。对于容器,你可以很直观地想象成多个元素在一起的单元;而不同容器的区别,正是在于内部数据结构的实现方法。然后,你就可以针对不同场景,选择不同时间和空间复杂度的容器。

所有的容器都是可迭代的(iterable)。这里的迭代,和枚举不完全一样。迭代可以想象成是你去买苹果,卖家并不告诉你他有多少库存。这样,每次你都需要告诉卖家,你要一

个苹果,然后卖家采取行为:要么给你拿一个苹果;要么告诉你,苹果已经卖完了。你并不需要知道,卖家在仓库是怎么摆放苹果的。

严谨地说,迭代器(iterator)提供了一个 next 的方法。调用这个方法后,你要么得到这个容器的下一个对象,要么得到一个 StopIteration 的错误(苹果卖完了)。你不需要像列表一样指定元素的索引,因为字典和集合这样的容器并没有索引一说。比如,字典采用哈希表实现,那么你就只需要知道,next 函数可以不重复不遗漏地一个一个拿到所有元素即可。

而可迭代对象,通过 iter() 函数返回一个迭代器,再通过 next() 函数就可以实现遍历。for in 语句将这个过程隐式化,所以,你只需要知道它大概做了什么就行了。

我们来看下面这段代码,主要向你展示怎么判断一个对象是否可迭代。当然,这还有另一种做法,是 isinstance(obj, lterable)。

```
1 def is_iterable(param):
```

² **try:**

³ iter(param)

⁴ return True

```
5
    except TypeError:
          return False
7
  params = [
9
       1234,
      '1234',
10
      [1, 2, 3, 4],
11
      set([1, 2, 3, 4]),
12
13
      {1:1, 2:2, 3:3, 4:4},
14 (1, 2, 3, 4)
15
16
17 for param in params:
      print('{} is iterable? {}'.format(param, is iterabl
19
20 ######## 输出 ########
21
22 1234 is iterable? False
23 1234 is iterable? True
24 [1, 2, 3, 4] is iterable? True
25 {1, 2, 3, 4} is iterable? True
26 {1: 1, 2: 2, 3: 3, 4: 4} is iterable? True
27 (1, 2, 3, 4) is iterable? True
```

通过这段代码, 你就可以知道, 给出的类型中, 除了数字 1234 之外, 其它的数据类型都是可迭代的。

生成器, 又是什么?

据我所知,很多人对生成器这个概念会比较陌生,因为生成器在很多常用语言中,并没有相对应的模型。

这里, 你只需要记着一点: **生成器是懒人版本的迭代器**。

我们知道,在迭代器中,如果我们想要枚举它的元素,这些元素需要事先生成。这里,我们先来看下面这个简单的样例。

```
1 def test_iterator():
2    show_memory_info('initing iterator')
3    list_1 = [i for i in range(100000000)]
4    show_memory_info('after iterator initiated')
```

```
5
       print(sum(list 1))
       show memory info('after sum called')
7
   def test generator():
       show memory info('initing generator')
       list 2 = (i for i in range(100000000))
       show memory info('after generator initiated')
11
12
       print(sum(list 2))
13
       show memory info('after sum called')
14
15 %time test iterator()
16 %time test generator()
17
18 ######## 输出 ########
19
20 initing iterator memory used: 48.9765625 MB
21 after iterator initiated memory used: 3920.30078125 MB
22 4999999950000000
23 after sum called memory used: 3920.3046875 MB
24 Wall time: 17 s
25 initing generator memory used: 50.359375 MB
26 after generator initiated memory used: 50.359375 MB
27 4999999950000000
28 after sum called memory used: 50.109375 MB
29 Wall time: 12.5 s
```

声明一个迭代器很简单, [i for i in range (100000000)]就可以生成一个包含一亿元素的列表。每个元素在生成后都会保存到内存中,你通过代码可以

看到,它们占用了巨量的内存,内存不够的话就会出现 OOM 错误。

不过,我们并不需要在内存中同时保存这么多东西,比如对元素求和,我们只需要知道每个元素在相加的那一刻是多少就行了,用完就可以扔掉了。

于是,生成器的概念应运而生,在你调用 next()函数的时候,才会生成下一个变量。生成器在 Python 的写法是用小括号括起来,(i for i in range(100000000)),即初始化了一个生成器。

这样一来,你可以清晰地看到,生成器并不会像迭代器一样 占用大量内存,只有在被使用的时候才会调用。而且生成器 在初始化的时候,并不需要运行一次生成操作,相比于 test_iterator(),test_generator() 函数节省了一次生成一 亿个元素的过程,因此耗时明显比迭代器短。

到这里,你可能说,生成器不过如此嘛,我有的是钱,不就是多占一些内存和计算资源嘛,我多出点钱就是了呗。

哪怕你是土豪,请坐下先喝点茶,再听我继续讲完,这次,我们来实现一个自定义的生成器。

生成器,还能玩什么花样?

数学中有一个恒等式, (1 + 2 + 3 + ... + n)^2 = 1^3 + 2^3 + 3^3 + ... + n^3, 想必你高中就应该学过它。现在, 我们来验证一下这个公式的正确性。老规矩, 先放代码, 你先自己阅读一下, 看不懂的也不要紧, 接下来我再来详细讲解。

```
1 def generator(k):
      i = 1
2
      while True:
         vield i ** k
5
          i += 1
6
7 gen 1 = generator(1)
8 gen 3 = generator(3)
9 print(gen 1)
10 print(gen 3)
11
12 def get sum(n):
      sum 1, sum_3 = 0, 0
13
      for i in range(n):
14
15
          next 1 = next(gen 1)
16
          next 3 = next(gen 3)
17
          print('next 1 = {}, next 3 = {}'.format(next 1,
          sum 1 += next 1
18
19
           sum 3 += next 3
      print(sum_1 * sum 1, sum 3)
20
21
22 get sum(8)
```

```
23
24 ######## 输出 ########
25
26 <generator object generator at 0x000001E70651C4F8>
27 <generator object generator at 0x000001E70651C390>
28 next_1 = 1, next_3 = 1
29 next_1 = 2, next_3 = 8
30 next_1 = 3, next_3 = 27
31 next_1 = 4, next_3 = 64
32 next_1 = 5, next_3 = 125
33 next_1 = 6, next_3 = 216
34 next_1 = 7, next_3 = 343
35 next_1 = 8, next_3 = 512
36 1296 1296
```

这段代码中,你首先注意一下 generator() 这个函数,它返回了一个生成器。

接下来的 yield 是魔术的关键。对于初学者来说,你可以理解为,函数运行到这一行的时候,程序会从这里暂停,然后跳出,不过跳到哪里呢?答案是 next() 函数。那么 i ** k 是干什么的呢?它其实成了 next() 函数的返回值。

这样,每次 next(gen) 函数被调用的时候,暂停的程序就又复活了,从 yield 这里向下继续执行;同时注意,局部变量 i 并没有被清除掉,而是会继续累加。我们可以看到 next_1 从 1 变到 8, next_3 从 1 变到 512。

聪明的你应该注意到了,这个生成器居然可以一直进行下去! 没错,事实上,迭代器是一个有限集合,生成器则可以成为一个无限集。我只管调用 next(),生成器根据运算会自动生成新的元素,然后返回给你,非常便捷。

到这里,土豪同志应该也坐不住了吧,那么,还能再给力一点吗?

别急,我们再来看一个问题:给定一个 list 和一个指定数字,求这个数字在 list 中的位置。

下面这段代码你应该不陌生,也就是常规做法,枚举每个元素和它的 index,判断后加入 result, 最后返回。

那么使用迭代器可以怎么做呢? 二话不说, 先看代码。

■ 复制代码

聪明的你应该看到了明显的区别,我就不做过多解释了。唯一需要强调的是, index_generator 会返回一个 Generator 对象,需要使用 list 转换为列表后,才能用 print 输出。

这里我再多说两句。在 Python 语言规范中, 用更少、更清晰的代码实现相同功能, 一直是被推崇的做法, 因为这样能够很有效提高代码的可读性, 减少出错概率, 也方便别人快速准确理解你的意图。当然, 要注意, 这里"更少"的前提

是清晰,而不是使用更多的魔术操作,虽说减少了代码却反而增加了阅读的难度。

回归正题。接下来我们再来看一个问题:给定两个序列,判定第一个是不是第二个的子序列。(LeetCode 链接如下:https://leetcode.com/problems/is-subsequence/)

先来解读一下这个问题本身。序列就是列表,子序列则指的是,一个列表的元素在第二个列表中都按顺序出现,但是并不必挨在一起。举个例子,[1, 3, 5] 是 [1, 2, 3, 4, 5] 的子序列,[1, 4, 3] 则不是。

要解决这个问题,常规算法是贪心算法。我们维护两个指针指向两个列表的最开始,然后对第二个序列一路扫过去,如果某个数字和第一个指针指的一样,那么就把第一个指针前进一步。第一个指针移出第一个序列最后一个元素的时候,返回 True, 否则返回 False。

不过,这个算法正常写的话,写下来怎么也得十行左右。

那么如果我们用迭代器和生成器呢?

```
2  b = iter(b)
3  return all(i in b for i in a)
4
5 print(is_subsequence([1, 3, 5], [1, 2, 3, 4, 5]))
6 print(is_subsequence([1, 4, 3], [1, 2, 3, 4, 5]))
7
8 ######### 输出 #########
9
10 True
11 False
```

这简短的几行代码, 你是不是看得一头雾水, 不知道发生了什么?

来,我们先把这段代码复杂化,然后一步步看。

```
1 def is subsequence(a, b):
       b = iter(b)
 2
       print(b)
 3
4
       gen = (i for i in a)
       print(gen)
6
7
       for i in gen:
8
9
           print(i)
10
       gen = ((i in b) for i in a)
11
       print(gen)
```

```
13
      for i in gen:
14
           print(i)
15
       return all(((i in b) for i in a))
17
18
19 print(is subsequence([1, 3, 5], [1, 2, 3, 4, 5]))
20 print(is_subsequence([1, 4, 3], [1, 2, 3, 4, 5]))
21
22 ######## 输出 ########
23
24 1 terator object at 0x000001E7063D0E80>
25 <generator object is_subsequence.<locals>.<genexpr> at
26 1
27 3
28 5
29 <generator object is subsequence.<locals>.<genexpr> at
30 True
31 True
32 True
33 False
34 1st iterator object at 0x000001E7063D0D30>
35 <generator object is subsequence.<locals>.<genexpr> at
36 1
37 4
38 3
39 <generator object is subsequence.<locals>.<genexpr> at
40 True
41 True
42 False
43 False
```

•

首先,第二行的b = iter(b),把列表 b 转化成了一个迭代器,这里我先不解释为什么要这么做。

接下来的gen = (i for i in a)语句很好理解,产生一个生成器,这个生成器可以遍历对象 a,因此能够输出 1,3,5。而 (i in b)需要好好揣摩,这里你是不是能联想到for in 语句?

没错,这里的(i in b),大致等价于下面这段代码:

```
■ 复制代码

1 while True:

2  val = next(b)

3  if val == i:

4  yield True
```

这里非常巧妙地利用生成器的特性, next() 函数运行的时候, 保存了当前的指针。比如再看下面这个示例:

```
1 b = (i for i in range(5))
2
3 print(2 in b)
4 print(4 in b)
5 print(3 in b)
```

```
6
7 ######## 输出 #######
8
9 True
10 True
11 False
```

至于最后的 all() 函数,就很简单了。它用来判断一个迭代器的元素是否全部为 True,如果是则返回 True,否则就返回 False.

于是到此,我们就很优雅地解决了这道面试题。不过你一定注意,面试的时候尽量不要用这种技巧,因为你的面试官有可能并不知道生成器的用法,他们也没有看过我的极客时间专栏。不过,在这个技术知识点上,在实际工作的应用上,你已经比很多人更加熟练了。继续加油!

总结

总结一下,今天我们讲了四种不同的对象,分别是容器、可 迭代对象、迭代器和生成器。

容器是可迭代对象,可迭代对象调用 iter() 函数,可以得到一个迭代器。迭代器可以通过 next() 函数来得到下一个元素,从而支持遍历。

生成器是一种特殊的迭代器(注意这个逻辑关系反之不成立)。使用生成器,你可以写出来更加清晰的代码;合理使用生成器,可以降低内存占用、优化程序结构、提高程序速度。

生成器在 Python 2 的版本上,是协程的一种重要实现方式;而 Python 3.5 引入 async await 语法糖后,生成器实现协程的方式就已经落后了。我们会在下节课,继续深入讲解 Python 协程。

思考题

最后给你留一个思考题。对于一个有限元素的生成器,如果 迭代完成后,继续调用 next() ,会发生什么呢? 生成器可 以遍历多次吗?

欢迎留言和我讨论,也欢迎你把这篇文章分享给你的同事、 朋友,一起在交流中进步。



© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪, 如有侵权极客邦将依法追究其法律责任。

上一篇 18 | [名师分享] metaclass, 是潘多拉魔盒还是阿拉丁...

下一篇 20 | 揭秘 Python 协程

精选留言 (39)





John Si 置顶 2019-06-21

我不知道如何把这技巧运用在编程中,老师能否举几个例子来说明一下呢?谢谢

作者回复: 例子已经在文中举了不少,对于如何娴熟地在编程中运用,这个需要长时间的积累,从阅读别人高质量的源代码,自己主动有意识地在自己的项目中思考,最后才会形成质变,内化成自己的能力,从而清楚地知道哪里应该用高级语法,高级工具,哪里应该简单的一笔带过。Python的生成器无疑是最有用的特性,但也是最不广泛被使用的特性,这一章的目的,能够让你对生成器有基本的了解,下次在代码中遇到,能够说,"这个我知道,这个我懂!"便已足够。加油!





思考题答案:

很多同学的回复非常正确,生成器只能遍历一次,继续调用 next() 会 raise StopIteration。只有复位生成器才能重新进行遍历。





Geek b04e76

2019-06-21

上一篇的分享mateclass写得看不懂,老师可否重新通俗写一下,分享嘉宾的风格跟老师不太一样啊





farFlight

2019-06-21

迭代完成后,继续调用 next()会出现StopIteration。 生成器只能遍历一次,但是可以重新调用重新遍历。

作者回复: 正确





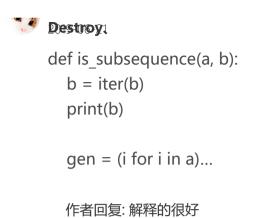
思考题:对于一个有限元素的生成器,如果迭代完成后,继续调用 next(),会跳出StopIteration:。生成器可以遍历多次吗?不行。也正是这个原因,老师代码复杂化那段代码,在

gen = ((i in b) for i in a)...

作者回复: 凸











tt 2019-06-21

明白为啥要把b转换成迭代器了,是为了下面的代码中可以用next():

while True:

val = next(b)...

作者回复: 对,这里是个很巧妙的利用



老师并没讲迭代器和可迭代对象区别,另外还有他们底层的实现,魔法方法





会引发StopIteration。 生成器只能使用一次。

作者回复: 凸





kyle

2019-06-21

gen = ((i in b) for i in a)

实际上是先遍历 a,取出一个值赋给i,然后再判断i是否在b中,判断一次,b中的指针后移一位。

所以,第一轮的输出应该是:TRUE,TRUE,TRUE(前三...





"接下来我们再来看一个问题:给定两个序列,判定第一个是不是第二个的子序列。"

老师,这个问题复杂版的代码为什么会有4个判断值。 true,true,false跟true,true,false,false





Monroe He

2019-06-24

列表元组字典集合都是可迭代对象,它们可以通过 iter() 函数返回一个迭代器,再通过next()函数就可以实现遍历,for in语句将整个过程隐式化。

```
gen = ((i in b) for i in a)
print(gen) ...
```







yshan

2019-06-24

while True: val = next(b) if val == i:

yield True

...







抛出StopIteration

·





Jon徐

2019-06-24

迭代器和生成器是以前只是在模块中碰到用一下,没有深入的理解过。迭代器只能遍历一次,只能向前遍历,不能回退。最后的例子使用这一特性将生成器和迭代器配合使用,非常巧妙,回味了很久。







小侠龙旋风

2019-06-23

>>> gen = (i for i in range(3))

>>> next(gen)

0

>>> next(gen)

1...







def next(iterator, default=None):

11 11 11

next(iterator[, default])

Return the next item from the iterator. If default...







Wing•三金

2019-06-22

思考题: 其实开头就已经明示了答案, 会出现 StopIteration Error。遍历是一次性, 参考下面这段代码:

def index_generator(L, target):...







Geek_59f23e

2019-06-22

呃。是我弄错了 next函数不设置默认值时迭代完成后调用它会抛出StopIteration。

如果指定default参数值,则不会抛出StopIteration,而是返回default值。







1、大家对next函数可能有些误区,迭代完成后继续调用 next函数会返回默认值None。

iterator.__next__() 方法和 next(iterator, default=None) 函数的区别在于:前者迭代完成后会抛 出StopIteration错误,中断程序运行,而后者会返回一...

作者回复: 凸

